Prédiction de Défauts de Paiement

Nom : MAZOUZ

Prénom :Imene

UE : Informatique Décisionnelle

1. Introduction

Dans le cadre de ce projet, nous nous intéressons à la prédiction du risque de défaut de paiement lors de l'octroi d'un emprunt bancaire.

L'objectif principal est de construire un modèle de classification supervisée capable de prédire si un client est susceptible de présenter un défaut de paiement (default = Oui) ou non (default = Non).

2. Préparation et nettoyage des données

2.1 Variable cible

La variable cible défaut indique si un client présente un défaut de paiement (Oui) ou non (Non). Elle a été transformée en facteur binaire, ce qui est nécessaire pour l'utilisation des modèles de classification.

2.2 Gestion des valeurs manquantes

Certaines variables numériques contiennent des valeurs codées par 999, correspondant à des valeurs manquantes. Ces valeurs ont été remplacées par des valeurs manquantes (NA), puis imputées par la médiane de la variable correspondante.

Le choix de la médiane permet de limiter l'influence des valeurs extrêmes. Cette méthode est simple, robuste et cohérente avec les méthodes vues en cours. Le même traitement est appliqué au jeu de données à prédire afin de garantir la cohérence du modèle.

2.3 Typage des variables

Les variables ont été typées selon leur nature :

éducation est considérée comme une variable ordinale, car les niveaux d'études sont hiérarchisés ;

catégorie est une variable catégorielle nominale ;

les autres variables sont traitées comme numériques.

Ce typage est important pour le bon fonctionnement des modèles utilisés.

3. Analyse exploratoire des données (EDA)

Une analyse exploratoire a été réalisée afin de mieux comprendre la structure des données et les relations entre les variables explicatives et le défaut de paiement.

3.1 Distribution du défaut

L'étude de la variable défaut montre que la majorité des clients ne présentent pas de défaut de paiement. Cela met en évidence un déséquilibre des classes, situation fréquente dans les problèmes de prédiction du risque bancaire.

3.2 Comparaison des variables explicatives selon le défaut

Des graphiques ont été utilisés pour analyser les relations entre certaines variables et la variable cible.

Un barplot comparant la variable catégorie avec le défaut montre que certaines catégories de clients présentent une proportion plus élevée de défauts. Cela suggère que cette variable peut être utile pour la prédiction.

De plus, l'étude de la distribution des probabilités prédites par la régression logistique montre une séparation partielle entre les clients en défaut et ceux sans défaut, ce qui justifie l'utilisation d'un seuil de décision ajustable.

4. Constitution des ensembles d'apprentissage et de test

Le jeu de données principal a été séparé en deux parties :

70 % des données pour l'apprentissage ;

30 % pour les tests.

La séparation a été réalisée de manière stratifiée, afin de conserver la proportion de clients en défaut dans les deux ensembles. Cette méthode permet d'obtenir une évaluation plus fiable des performances des modèles.

5. Modèles de classification

Deux modèles de classification supervisée vus en cours ont été utilisés et comparés.

5.1 Régression logistique

La régression logistique est particulièrement adaptée aux problèmes de classification binaire. Elle permet d'obtenir une probabilité de défaut, ce qui est très utile pour ajuster le seuil de décision selon le niveau de risque souhaité.

Deux seuils ont été testés :

0.5, seuil standard ;

0.4, afin d'augmenter la détection des clients à risque.

5.2 Arbre de décision

Un arbre de décision a également été entraîné afin de comparer ses performances avec celles de la régression logistique. Ce modèle est simple à interpréter, mais peut être moins performant lorsque les relations entre variables sont complexes.

6.Évaluation des modèles

6.1 Matrices de confusion

Les performances des modèles ont été analysées à l'aide de matrices de confusion, qui permettent d'identifier :

Les vrais positifs, les faux positifs, les vrais négatifs, les faux négatifs.

Dans le contexte bancaire, les faux négatifs sont particulièrement problématiques, car ils correspondent à des clients risqués classés comme non risqués.

6.2 Mesures de performance

Les modèles ont été évalués à l'aide :

Du rappel (recall), mesure prioritaire dans ce projet ;

des courbes ROC ;

de l'AUC (Area Under the Curve).

Les résultats montrent que la régression logistique présente une AUC plus élevée que l'arbre de décision. De plus, l'abaissement du seuil de décision à 0.4 permet d'améliorer significativement le rappel, au prix d'une augmentation modérée des faux positifs.

7. Comparaison des modèles et choix final

La comparaison des modèles montre que :

la régression logistique est globalement plus performante que l'arbre de décision ;

le seuil de 0.4 permet une meilleure détection des clients en défaut ;

l'arbre de décision est moins performant en termes de rappel et d'AUC.

Ainsi, le modèle retenu est la régression logistique avec un seuil de décision de 0.4, car il offre le meilleur compromis entre performance globale et gestion du risque bancaire.

8. Application aux données prospects

Le modèle final a été appliqué au jeu de données Data Projet New.csv, contenant 500 nouveaux clients. Pour chaque client, le modèle fournit :

une prédiction du défaut (Oui / Non) ;

une probabilité associée à cette prédiction.

Les résultats ont été exportés dans un fichier FINAL_RESULTS.csv, conforme aux consignes du projet.

9. Conclusion

Ce projet a permis de mettre en pratique les principales étapes d'un processus de classification supervisée :

préparation et nettoyage des données ;

analyse exploratoire ;

apprentissage et évaluation de plusieurs modèles ;

comparaison et choix d'un modèle final ;

application à de nouvelles données.

La régression logistique s'est révélée être le modèle le plus adapté à cette problématique. L'ajustement du seuil de décision permet d'intégrer une logique de gestion du risque, essentielle dans un contexte bancaire.